Cahier de TP « Messagerie distribuée avec Kafka »

Pré-requis:

- Bonne connexion Internet
- Système d'exploitation recommandé : Linux
- JDK21+, Maven
- IDE Recommandés : STS 4, IntelliJIDEA, VSCode
- Docker, Git

Images utilisées:

- docker.io/bitnami/kafka:3.7
- tchiotludo/akhq
- docker.redpanda.com/redpandadata/console:latest
- confluentinc/cp-schema-registry
- postgres:15.1
- dpage/pgadmin4
- docker.elastic.co/elasticsearch/elasticsearch:7.7.1
- docker.elastic.co/kibana/kibana:7.7.1

Table des matières

Atelier 1: Le cluster kafka	3
1.1 Premier démarrage et logs	3
1.2 Utilisation des utilitaires	3
1.3 Outils graphiques	3
Atelier 2: Producer API	4
Atelier 3 : Consumer API	5
3.0 Mise en place d'une base Postgres	5
3.1 Implémentation	5
3.2 Tests	6
Atelier 4. Sérialisation Avro	7
4.1 Ajout de Confluent Schema Registry	7
4.2 Producteur de message	7
4.3 Consommateur de message	8
4.4 Mise à jour du schéma	8
4.4.1 Evolution du schéma compatible	8
4.4.2 Evolution du schéma incompatible	8
Atelier 5. Kafka Connect	
5.1 Installations ElasticSearch	9
5.2 Installation connecteur ElasticSearch	9
5.3 Configuration du connecteur	
Atelier 6 : Garanties Kafka	
6.1. Transaction et ISOLATION_LEVEL	
6.1.1 Producteur transactionnel	
6.1.2 Consommateur	11
6.2 Transfert Exactly Once	
6.3 Stockage et rétention	
Ouvrir un bash sur un des nœuds	11

Visualiser les répertoires de logs sur les brokers :	11
Visualiser les segments du topic position et apprécier la taille	11
Pour le topic position modifier le segment.bytes à 1Mo	
Diminuer le retention.bytes	11
Produire de nombreux messages afin de voir des segments disparaître	11
Atelier 7 : Introduction à KafkaStream	
7.1 Opérateurs stateless	12
7.2 Opérateurs stateful	12
Atelier 8: ksqlDB	13
8.1 Getting started	
Ateliers 9: Sécurité	15
9.1 Séparation des échanges réseaux	15
9.2 Accès via SSL au cluster	15
9.3 Authentification avec SASL/PLAIN	15
9.3.1 Authentification inter-broker	15
9.3.2 Authentification client	16
9.4 ACL	16
9.5 Quotas	16
Atelier 10. Frameworks	18
10.1 MP Messaging avec Quarkus	18
10.2 Production et Consommation de message avec Spring Kafka	18
10.3 Spring Cloud Stream	18
Atelier 11: Annexes	19
11.1 Métriques JMX et mise en place monitoring Prometheus, Grafana	19

Atelier 1: Le cluster kafka

1.1 Premier démarrage et logs

Visualiser le fichier *docker-compose.yml*

Il permet de démarrer un cluster 3 nœuds ainsi que 2 containers utiles pour l'administration du cluster

Démarrer cette stack avec :

docker compose up -d

Observer les logs de démarrages d'un noeud

docker logs -f kafka-0

1.2 Utilisation des utilitaires

Ouvrir un bash sur un des nœuds

docker exec -it kafka-0 bash

Se positionner dans les répertoires des utilitaires :

cd /opt/bitnami/kafka/bin/

Créer un topic *testing* avec 5 partitions et 2 répliques :

./kafka-topics.sh --create --bootstrap-server localhost:9092 --replicationfactor 2 --partitions 5 --topic testing

Lister les topics du cluster

Accéder à la description détaillée du topic

Démarrer un producteur de message

```
./kafka-console-producer.sh --broker-list localhost:9092 --topic testing --
property "parse.key=true" --property "key.separator=:"
```

Saisir quelques messages

Consommer les messages depuis le début

```
./kafka-console-consumer.sh --bootstrap-server localhost:9092 --topic testing --from-beginning
```

Dans une autre fenêtre, lister les groupes de consommateurs et accéder au détail du groupe de consommateur en lecture sur le topic *testing*

1.3 Outils graphiques

Parcourir l'UI des 2 outils graphiques fournis :

akhq: http://localhost:8080

Redpanda Console: http://localhost:9090

Atelier 2: Producer API

Importer le projet Maven fourni

Le projet est composé de :

- Une classe principale *KafkaProducerApplication* qui prend en arguments :
 - *nbThreads* : Un nombre de threads
 - o *nbMessages*: Un nombre de messages
 - *sleep* : Un temps de pause en ms
 - o *sendMode*: Le mode d'envoi : 0 pour Fire_And_Forget, 1 pour Synchrone, 2 pour Asynchrone

L'application instancie *nbThreads KafkaProducerThread* et leur demande de s'exécuter ; quand toutes les threads sont terminées. Elle affiche le temps d'exécution

- Une classe *KafkaProducerThread* qui une fois instanciée envoie *nbMessages* tout les temps de pause selon un des 3 modes d'envoi.
 - Les messages sont constitués d'une au format String (*courier.id*) et d'une payload au format JSON (classe *Courier*)
- Le package *model* contient les classes modélisant les données
 - *Position* : Une position en latitude, longitude
 - *Courier* : Un coursier associé à une position
 - **SendMode**: Une énumération des modes d'envoi

Compléter les méthodes d'envoi de *KafkaProducerThread*.

Pour cela vous devez:

- Initialiser un *KafkaProducer*<*String,Courier*> et y positionner des sérialiseurs JSON pour la classe *Courier*
- Construire un ProducerRecord pour chaque messages
- Implémenter les 3 méthodes d'envoi

Tester l'envoi de messages dans les différents dans l'IDE

Via les commandes utilitaires ou l'interface d'admin, vérifier la création du topic et le contenu des messages

Construire un jar exécutable avec :

mvn package

Supprimer le topic et le recréer avec un nombre de *partitions=5* et un *replication-factor=3*

Envoyer 1M de messages, par exemple :

java -jar target/producer-0.0.1-SNAPSHOT-jar-with-dependencies.jar 500 2000 10 1

Atelier 3: Consumer API

3.0 Mise en place d'une base Postgres

Démarrer un serveur postgres et sa console d'administration docker compose -f postgres-docker-compose.yml up -d

Accéder à *localhost:81* et se logger avec *admin@admin.com/admin* Enregistre un serveur avec comme paramètres de connexion :

• host : consumer-postgresql

user : *postgres*password : *postgres*

Créer une base consumer et y exécuter le script de création de table fourni : *create-table.sql*

3.1 Implémentation

Le projet est composé de :

- Une classe principale *KafkaConsumerApplication* qui prend en arguments :
 - o **nbThreads**: Un nombre de threads

L'application instancie *nbThreads KafkaConsumerThread* et leur demande de s'exécuter. Le programme s'arrête au bout d'un certains temps.

- Une classe *KafkaConsumerThread* qui une fois instanciée poll le topic position Le traitement d'un message consiste à un insérer un enregistrement en BD
- Le package model contient les classes modélisant les données
 - **Position**: Une position en latitude, longitude
 - *Courier* : Un coursier associé à une position

Compléter la boucle de réception des messages

Pour cela, vous devez

- Initialiser un KafkaConsumer avec la propriété

 ConsumerConfig.AUTO_OFFSET_RESET_CONFIG à « earliest »
- Fournir un Deserialiseur
- Implémenter la boucle de réception, pour chaque enregistrement reçu stocker dans la base postgres id du coursier et l'offset kafka en utilisant la classe *ConsumerDao*

Pour tester la réception, vous pouvez utiliser le programme précédent et le lancer afin qu'il exécute de nombreux message :

Par exemple:

```
producer_home$ java -jar target/producer-0.0.1-SNAPSHOT-jar-with-
dependencies.jar 10 100000 500 0
```

Implémenter un *ConsumerRebalanceListener* et l'associer au moment du *subscribe()*

3.2 Tests

Une fois le programme mis au point, construire l'application avec :

mvn clean package

effectuer plusieurs tests, entre chaque démarrage effacer les offsets du groupe et nettoyer la base de données

Tester qu'aucun message n'est perdu :

Démarrer le programme avec 3 thread

java -jar target/consumer-0.0.1-SNAPSHOT-jar-with-dependencies.jar 3 10

Visualiser la répartition des partitions

Arrêter puis redémarrer avec la même configuration

<u>Tester la réaffectation de partitions :</u>

Démarrer 2 fois l'application : 1 avec 2 threads l'autre avec 3 threads

java -jar target/consumer-0.0.1-SNAPSHOT-jar-with-dependencies.jar 2 10

java -jar target/consumer-0.0.1-SNAPSHOT-jar-with-dependencies.jar 3 10

visualiser la répartition des partitions

Arrêter et redémarrer un processus pendant la consommation

Test redémarrage broker

Arrêter un broker:

docker stop kafka-0

Redémarrer le, Dans le répertoire du fichier docker-compose

docker compose up -d

Essayer de vérifier le traitement de tous les messages. (Il se peut qu'il y ait des doublons de traitement)

Atelier 4. Sérialisation Avro

4.1 Ajout de Confluent Schema Registry

Visualiser le fichier *docker-compose.yml* fournis

Démarrer la stack

Accéder à *localhost:8081/subjects*

Visualiser dans la Redpanda Console le schema registry

4.2 Producteur de message

Créer un nouveau projet Maven *producer-avro*Récupérer le **pom.xml** fourni
Mettre au point un **schéma Avro : src/main/resources/Courier.avsc**Effectuer un *mvn compile* et regarder les classes générées par le plugin Avro

```
Reprendre les classes du projet producer sans les classes du modèle

Dans la classe main, poster le schéma dans le serveur registry:

String schemaPath = "/Courier.avsc";

// subject convention is "<topic-name>-value"

String subject = TOPIC + "-value";

InputStream inputStream =

KafkaProducerApplication.class.getResourceAsStream(schemaPath);

Schema avroSchema = new Schema.Parser().parse(inputStream);

CachedSchemaRegistryClient client = new

CachedSchemaRegistryClient(REGISTRY_URL, 20);
```

Dans le producteur de message modifier la classe *KafkaProducerThread* afin

- qu'elle compile
- qu'elle utilise un sérialiseur de valeur de type

client.register(subject, avroSchema);

io.confluent.kafka.serializers.KafkaAvroSerializer

• Qu'elle renseigne la clé

AbstractKafkaSchemaSerDeConfig.SCHEMA REGISTRY URL CONFIG

Modifier le nom du *topic* d'envoi et tester la production de message.

Accéder à localhost:8081/subjects

Puis à Accéder à localhost:8081/schemas/

Vérifier que *akhq, redpanda* puissent lire les messages.

4.3 Consommateur de message

Reprendre le même *pom.xml* que le projet *producer-avro* Ne plus utiliser les classes de modèle mais la classe d'Avro *GenericRecord* Modifier les propriétés du consommateur :

• Le désérialiseur de la valeur à :

"io.confluent.kafka.serializers.KafkaAvroDeserializer"

• La propriété *schema.registry.url*

Consommer les messages du topic précédent

4.4 Mise à jour du schéma

4.4.1 Evolution du schéma compatible

Fixer les problèmes de compilation

Relancer le programme de production et visualiser la nouvelle version du schéma dans le registre Consommer les messages sans modifications du programme consommateur

4.4.2 Evolution du schéma incompatible

Fixer les problèmes de compilation

Relancer le programme de production et visualiser l'exception au moment de l'enregistrement du nouveau schéma.

Visualiser les nouveaux messages publiés dans le topic

Atelier 5. Kafka Connect

Objectifs: Déverser le topic position dans un index ElasticSearch

5.1 Installation du plugin ElasticSearch dans kafka connect

Visualiser le fichier Dockerfile fourni et construire une image *my-kafka-connect-with-elasticsearch* via :

docker build -t my-kafka-connect-with-elasticsearch .

5.2 Démarrage de la stack

Démarrer la nouvelle stack qui ajoute l'image précédemment construite, ElasticSearch et Kibana docker-compose up -d

Vérifier l'installation du plugin via :

http://localhost:8083/connector-plugins

Se connecter à kibana localhost :5601 et dans la DevConsole exécuter :

La commande crée un index elasticsearch *position* avec pour l'instant un seul champ @timestamp

5.3 Configuration du connecteur

Définir un connecteur *elasticsearch-sink* qui déverse le topic position dans l'index position :

```
curl -X POST http://localhost:8083/connectors \
-H "Content-Type: application/json" \
-d '{
"name": "elasticsearch-sink",
"config": {
"connector.class":
```

```
"io.confluent.connect.elasticsearch.ElasticsearchSinkConnector",
"tasks.max": "1",
"topics": "position",
"topic.index.map": "position:position_index",
"connection.url": "http://elasticsearch:9200",
"type.name": "log",
"key.ignore": "true",
"schema.ignore": "true",
"key.converter": "org.apache.kafka.connect.json.JsonConverter",
"key.converter.schemas.enable": "false",
"value.converter": "org.apache.kafka.connect.json.JsonConverter",
"value.converter.schemas.enable": "false"
}
}'
```

Vous pouvez vérifier la bonne installation du connecteur :

- Via les logs de KafkaConnect
- Via http://localhost:8083 /connectors : Liste des connecteurs actifs
- Via l'interface de RedPanda

Alimenter le topic position

Vous pouvez visualiser les effets du connecteur

- Via ElasticSearch : http://localhost:9200/position/_search
- Via Kibana : http://localhost:5601

5.3 Améliorations

Améliorer le fichier de configuration afin que le timestamp Kafka soit renseigné dans le champ **@timestamp** de l'index d'ElasticSearch

Créer un autre connecteur pour déverser le topic *position-avro* dans un index *position-avro*

Atelier 6: Garanties Kafka

6.1. Transaction et ISOLATION_LEVEL

6.1.1 Producteur transactionnel

Modifier le code du producer afin d'englober plusieurs envois de messages dans une transaction.

Commiter tous les 10 envois

Lancer ensuite le programme avec comme arguments 1 **105** 100 0

Ce qui signifie que 1 threads envoie 105 messages, les 100 premiers messages font partie de 10 transactions validées. Les 5 derniers messages ne sont pas validés.

Visualiser les messages dans une console d'administration.

Noter le nombre et les offsets, Visualiser le flag transactionnel

6.1.2 Consommateur

Modifier la configuration du consommateur afin qu'il ne lise que les messages committés

6.2 Transfert Exactly Once

Modifier le consommateur afin qu'il transfert exactement une fois les messages produits en amont vers un autre topic de sortie

Éventuellement on peut effectuer un traitement du message comme calculer la distance à un point d'origine.

Vérifier les messages produits et les offsets consommés

6.3 Stockage et rétention

Ouvrir un bash sur un des nœuds

docker exec -it kafka-0 bash

Visualiser les répertoires de logs sur les brokers :

kafka-log-dirs.sh --bootstrap-server localhost:9092 --describe

Visualiser les segments du topic position et apprécier la taille

Pour le topic position modifier le segment.bytes à 1Mo

Diminuer le *retention.bytes*

Produire de nombreux messages afin de voir des segments disparaître

Atelier 7: Introduction à KafkaStream

Objectifs:

Écrire une application Stream qui prend en entrée le topic *position-avro*

7.1 Opérateurs stateless

Créer un projet **PositionStream** et installer le package

io.confluent:kafka-avro-serializer

Reprendre le schéma Avro initial du producteur Avro et générer les classes du modèle

• Dans un premier temps, transformer les informations de la position d'un coursier en arrondissant la longitude et la latitude à 1 valeur entière.

Tester, regarder les timestamp des messages

Supprimer le topic de sortie

- Compléter le stream en inversant les clés et Valeurs (La position du coursier devient la clé, l'id du coursier la valeur)
 Tester
- Utiliser branch pour créer 2 topic de sortie un contenant les positions dont la latitude est supérieure à 45.0 et l'autre le reste Tester

7.2 Opérateurs stateful

Sur les branches précédentes, effectuer une agrégation de type Count(), i.e compter le nombre de coursier ayant passé à une position donné.

Tester

Modifier en utilisant une fenêtre temporelle de 1 seconde.

Utiliser l'opération reduce pour avoir en temps-réel, la liste des coursiers associés à une position.

Atelier 8: ksqlDB

8.1 Getting started

```
Démarrer la stack avec le docker compose fourni.
Ensuite, démarrer une console interactive ksql-cli
docker exec -it ksqldb-cli ksql http://ksqldb-server:8088
Créer un stream associé à un topic
CREATE STREAM riderLocations (profileId VARCHAR, latitude DOUBLE, longitude
DOUBLE) WITH (kafka_topic='locations', value_format='json', partitions=1);
Créer une table contenant les derniers emplacements des riderLocation
CREATE TABLE currentLocation AS
SELECT profileId,
LATEST_BY_OFFSET(latitude) AS la,
LATEST_BY_OFFSET(longitude) AS lo
FROM riderlocations
GROUP BY profileId
EMIT CHANGES;
Créer une table contenant les données agrégées (liste de coursier, nombre) par distance par rapport à
un point d'origine
CREATE TABLE ridersNearMountainView AS
SELECT ROUND(GEO_DISTANCE(la, lo, 37.4133, -122.1162), -1) AS distanceInMiles,
COLLECT_LIST(profileId) AS riders,
COUNT(*) AS count
FROM currentLocation
GROUP BY ROUND(GEO_DISTANCE(la, lo, 37.4133, -122.1162), -1);
Exécuter une PUSH QUERY
-- Mountain View lat, long: 37.4133, -122.1162
SELECT * FROM riderLocationsWHERE GEO_DISTANCE(latitude, longitude, 37.4133, -
122.1162) <= 5 EMIT CHANGES;
Démarrer une autre session :
docker exec -it ksqldb-cli ksql http://ksqldb-server:8088
INSERT INTO riderLocations (profileId, latitude, longitude) VALUES ('c2309eec',
37.7877, -122.4205);
INSERT INTO riderLocations (profileId, latitude, longitude) VALUES ('18f4ea86',
37.3903, -122.0643);
INSERT INTO riderLocations (profileId, latitude, longitude) VALUES ('4ab5cbad',
37.3952, -122.0813);
INSERT INTO riderLocations (profileId, latitude, longitude) VALUES ('8b6eae59',
37.3944, -122.0813);
```

INSERT INTO riderLocations (profileId, latitude, longitude) VALUES ('4a7c7b41',
37.4049, -122.0822);

INSERT INTO riderLocations (profileId, latitude, longitude) VALUES ('4ddad000',
37.7857, -122.4011);

Puis exécuter une PULL QUERY

SELECT * from ridersNearMountainView WHERE distanceInMiles <= 10;</pre>

Ateliers 9: Sécurité

9.1 Séparation des échanges réseaux

Le fichier *docker-compose* sépare déjà sur des ports différents la communication contrôleurs, brokers et client externe .

Visualisez la configuration bitnami des listeners

9.2 Accès via SSL au cluster

Redémarrer le cluster en utilisant la nouvelle version de docker-compose, le port EXTERNAL utilise dorénavant SSL

Récupérer le répertoire SSL qui contient un keystore et un trustore self-signed pour localhost

Modifier *docker-compose.yml* afin que le répertoire *ssl/mount* soit correctement monté sur chaque broker.

Démarrer le cluster et vérifier le certificat produit par le serveur :

```
openssl s_client -debug -connect localhost:19092 -tls1_2
```

Modifier les propriétés du client SpringProducer afin qu'il utilise le protocle SSL pour communiquer

```
ssl:
   trust-store-location: <path-to>/ssl/mount/kafka.truststore.jks
   trust-store-password: secret
security:
   protocol: SSL
```

Vérifier la production de message

9.3 Authentification avec SASL/PLAIN

9.3.1 Authentification inter-broker

Mettre au point un fichier *kafka_jaas.conf* définissant 2 utilisateurs *admin* et *alice* et indiquant que le serveur utilise l'identité *admin* comme suit :

```
KafkaServer {
    org.apache.kafka.common.security.plain.PlainLoginModule required
    username="admin"
    password="admin-secret"
```

```
user_admin="admin-secret"
user_alice="alice-secret";
};
```

Récupérer la nouvelle version de docker-compose et vérifier le montage de volume vers votre fichier *kafka_jaas.conf*

Redémarrer le cluster et vérifier son bon démarrage

9.3.2 Authentification client

```
Mettre à jour un fichier client-ssl.properties comme suit :
security.protocol=SASL_SSL
sasl.mechanism=PLAIN
sasl.jaas.config=org.apache.kafka.common.security.plain.PlainLoginModule required \
username="alice" \
password="alice-secret";

Tester avec :
$KAFKA_DIST/bin/kafka-topics.sh --bootstrap-server localhost:19092 --list --command-config ssl/client-ssl.properties
```

Configurer le projet SpringProducer pour qu'il s'authentifie avec l'utilisateur alice

Tester l'envoi de message, vérifier la bonne configuration du *KafkaProducer* et la production de message

9.4 ACL

Visualiser la nouvelle configuration des brokers dans le nouveau *docker-compose.yml* Démarrer le cluster.

Vérifier via Redpanda Console que le lien sécurité permet de créer des ACLs Interdire à Alice la production de message et tester

9.5 Quotas

Se créer un ficier *client-admin.properties* permettant de se logger avec l'utilisateur admin

Définition d'un quota pour l'utilisateur alice

```
$KAFKA_DIST/bin/kafka-configs.sh --bootstrap-server localhost:9094 --alter --
add-config 'producer_byte_rate=1024,consumer_byte_rate=1024' --entity-type users
--entity-name alice --command-config client-admin-ssl.properties
```

Relancer SpringProducer et observer les messages d'erreurs produits

Supprimer les quotas :

```
$KAFKA_DIST/bin/kafka-configs.sh --bootstrap-server localhost:9094 --alter --delete-config producer_byte_rate --entity-type users --entity-name alice --command-config client-admin-ssl.properties
```

\$KAFKA_DIST/bin/kafka-configs.sh --bootstrap-server localhost:9094 --alter --delete-config consumer_byte_rate --entity-type users --entity-name alice --command-config client-admin-ssl.properties

Atelier 10. Frameworks

<u>Objectifs</u>: Utiliser les frameworks Spring et Quarkus pour consommer les enregistrements du topic *position* précédent

10.1 MP Messaging avec Quarkus

Récupérer le projet Maven/Quarkus fourni.

Le fichier *pom.xml* déclare en particulier les dépendances suivantes :

- quarkus-smallrye-reactive-messaging-kafka
- quarkus-resteasy-reactive-jackson

Déclarer un Bean PositionService déclarant un méthode de réception de message

Dans le fichier de configuration *src/main/resources/application.properties* :

• Déclarer les bootstrap-servers Kafka

Pour démarrer l'application :

mvn quarkus:dev

Tester en alimentant le topic

10.2 Production et Consommation de message avec Spring Kafka

Reprendre les 2 projets SpringKafka fourni et les comprendre.

Supprimer le topic position, nettoyer la base PostgreSQL et exécuter SpringProducer et SpringConsumer

10.3 Spring Cloud Stream

Récupérer le projet Maven/SpringBoot fourni.

Le fichier *pom.xml* déclare en particulier les dépendances suivantes :

- spring-cloud-stream
- spring-cloud-stream-binder-kafka

Déclarer un Bean Spring ayant pour nom *position* de type *Consumer*<*Message*<*String*>>

Dans le fichier de configuration *src/main/resources/application.yml* :

- Utiliser le nom de la méthode annotée Bean pour binder le topic *position*
- Déclarer les bootstrap-servers Kafka

Tester en alimentant le topic

Atelier 11: Annexes

Exécuter les producteurs et les consommateurs pendant les opérations d'administration

11.1 Métriques JMX et mise en place monitoring Prometheus, Grafana

Dans un premier temps, démarré une JConsole et visualiser les Mbeans des brokers, consommateurs et producteurs

Visualiser le nouveau *docker-compose.yml* qui :

- Attache l'agent jmx_prometheus_javaagent-0.20.0.jar aux processus Java des brokers
- Intègre et configure les services Prometheus et Grafana

Produire et consommer

Vérifier la production de métriques par chaque broker :

http://localhost:7071

Vérifier la récupération des métriques dans Prometheus :

http://localhost:9091

Connecter-vous à Grafana

http://localhost:3000 avec admin/admin

Vérifier la datasource Prometheus

Importer le tableau de bord : https://grafana.com/grafana/dashboards/721

Les métriques des brokers devraient s'afficher